


PatylA: Arquitectura y Blueprint del Sistema

Orquestación técnica,
persistencia y flujo RAG
del asistente
conversacional
(AYUDASCP-IA).

Documentación
de Ingeniería v1.0




1

Leyenda de Infraestructura

Microservicio HTTP: 8 funciones serverless aisladas gestionan el contrato de la API.

Almacenamiento Vectorial: Integración nativa vía file-search para habilitar el contexto RAG del asistente.

Autenticación Desacoplada: Validación de credenciales delegada al microservicio de Contactos.





1



Cierre Automático (Regla de 4 Horas)

Al consultar una conversación vía GET, si la diferencia entre la hora actual y FHULTACT (último mensaje) supera las 4 horas, el sistema muta el estado automáticamente a CERRADO.

2



Borrado Lógico

El endpoint DELETE no destruye registros físicamente. Actualiza el estado de la conversación a NO VISIBLE, excluyéndola de los listados del usuario.

3



Singularidad del Tiquete

Una conversación soporta un máximo estricto de un (1) tiquete escalado. El endpoint POST-Tiquete bloquea activamente duplicidades.

The diagram illustrates a four-step process flow for handling OpenAI threads and streaming responses. It features four numbered steps, each represented by a red sphere with a glowing cyan number. The steps are connected by a continuous, wavy, glowing cyan line that resembles a circuit or data stream. The background is dark with a subtle geometric pattern of hexagons and lines.

1

Resolución del Hilo (Thread)

Se evalúa la petición. Si no existe un hilo de OpenAI asociado, se crea uno nuevo. El prompt del usuario se adjunta a este hilo.

2

Inicio de Transmisión

Se dispara la petición al asistente y se retorna inmediatamente un indicador de inicio de stream al frontend.

3

Recepción en Vivo

El frontend procesa y muestra los chunks (fragmentos de datos) al usuario a medida que OpenAI los genera.

4

Persistencia Asíncrona

Al confirmar la finalización del stream, se actualiza la BD: se registran los tokens consumidos, la cantidad total de mensajes, el modelo utilizado y la fecha de actualización.

Flujo de Seguridad - POST /JWT

1

1. Intercepción Inicial

El usuario intenta autenticarse; el Frontend envía credenciales opacas al Backend de PatylA.

2

2. Validación Externa

El Backend delega la validación de la identidad consultando el servicio satélite LoginContacto en DSCLIENTES.

3

3. Denegación o Emisión

Fallo: Si la controlkey es inválida, se aborta.

Éxito: El servicio emite un JSON Web Token (JWT) firmado localmente, encapsulando las variables de sesión.



Todos los endpoints requieren validación
previa de JWT y carga de sesión.

[POST]

/Conversacion

Propósito: Crea o continúa una conversación.
Solicita título a la IA en creaciones.

Mecánica: Retorna apertura de stream; finaliza
persistiendo metadatos (tokens, modelo).

[GET]

/Conversaciones

Propósito: Lista el historial del usuario.

Filtro: Excluye estrictamente registros marcados
como NO VISIBLES.

[GET]

/Conversacion/{id}

Propósito: Hidrata la interfaz del chat.

Carga: Obtiene historial de OpenAI + mensajes
calificados locales + tiquetes. *Aplica regla de 4 horas.*

[GET]

/Conversacion/{id}/Resumen

Propósito: Síntesis ejecutiva de la charla.
Delega a OpenAI la generación basada en el hilo.

Matriz de Escalamiento y
Escalamiento y Feedback.

[POST]

/Mensaje

Propósito: Registra feedback explícito del usuario.
Efecto: Inserta en MENSAJESCALIFICADOS vinculando ID de conversación, hilo y flag de utilidad (BUTIL).

[POST]

/Tiquete

Propósito: Escala la conversación inconclusa a soporte humano.
Restricción: Verifica TIQUETESCONVERSACION; aborta si ya existe un tiquete vinculado.

[DELETE]

/Conversacion/{id}

Propósito: Permite al usuario eliminar una charla de su vista.
Ejecución: Operación de mutación suave. Establece ITDESTADO = NO VISIBLE.



Conclusión: PatyIA proporciona un acoplamiento seguro y persistente entre la IA conversacional avanzada y la gestión transaccional de usuarios y tiquetes.