


Orquestación Técnica de Patyla

Arquitectura, Modelo de
Datos y Flujos API del
Asistente RAG




Mapa Conceptual de Actores

El ecosistema interactúa a través del microservicio central AYUDASCP-IA para garantizar seguridad y contexto.



Arquitectura de Componentes en Azure

AYUDASCP-IA actúa como un middleware seguro entre el cliente web, los modelos de lenguaje y la persistencia de datos.



Modelo de Persistencia Estricta

La base de datos AYUDASCP_IA centraliza el estado, asegurando trazabilidad y control de costos.

CONVERSACIONES (Núcleo)

- Mantiene referencias externas (HILO).
- Audita consumos (QMENSAJES, QTOKENS).
- Almacena el PROMPT inicial.

Relaciones de 1 a N

- Mensajes Calificados: Mapea calificaciones de utilidad al hilo.
- Tiquetes: Máximo un (1) tiquete escalado por conversación.




Matriz de Estados Conversacionales

El ciclo de vida de una conversación muta según la actividad del usuario y las reglas de retención.

Estado	Condición de Activación	Acción del Backend	Vista en Frontend
 Nueva	Primer POST sin ID previo.	Crea registro e HILO en OpenAI.	Chat en blanco, inicia stream.
 Activa	Interacción continua.	Actualiza HILO, suma QTOKENS.	Historial completo disponible.
 Cerrada	> 4 horas desde el último mensaje.	Muta el estado a CERRADO automáticamente.	Chat de solo lectura.
 No Visible	Ejecución de DELETE-Conversacion.	Borrado lógico. Oculta el registro.	Desaparece del listado.

El Motor RAG en Movimiento (Flujo de Streaming)

PatyIA optimiza la percepción de latencia aislando la persistencia de la transmisión de datos.



Seguridad de Perímetro: Handshake de Autenticación

Todas las funciones HTTP operan bajo validación estricta de JWT.



1. Delegación:

El frontend envía credenciales al microservicio externo LoginContacto.

2. Firma del Servicio:

Si es auténtica, AYUDASCP-IA genera un token JWT firmado.

3. Barrera Cero-Confianza:

Cada request subsecuente requiere que el backend valide el JWT y la propiedad del registro.


Matriz de Endpoints: El Panel de Control

Las 8 interfaces HTTP sin estado orquestan el comportamiento del sistema.

Identidad y Acceso		Ciclo de Vida del Chat	
POST-JWT (Emisión y firma de token)		POST-Conversion (Creación y streaming)	
		GET-Conversaciones (Listado visible)	GET-Conversion (Historial profundo por ID)
Síntesis y Contexto		Retroalimentación y Escalamiento	
GET-ResumenConversion (Compresión de hilos con IA)		POST-Mensaje (Registro de calificaciones)	POST-Tiquete (Creación de casos)
		DELETE-Conversion (Borrado lógico)	




POST-Conversacion: El Motor de Interacción

Manejo dinámico de creación de hilos y recuperación de contexto.



Orquestación de Sistemas por Tipo de Operación

Cómo interactúa el middleware dependiendo del requerimiento del cliente.

Tipo de Operación 	DSCLIENTES (Auth) 	DB MSSQL (Estado) 	Proveedor IA (Contexto) 
Read (GET) 	Valida JWT 	Consulta registros, valida regla de cierre (>4h). 	Recupera hilos, genera resúmenes. 
Write (POST, DELETE) 	Valida JWT 	Inserta/Actualiza entidades, valida restricciones. 	N/A 
Stream (Chat) 	Valida JWT 	Espera al fin del stream para actualizar tokens. 	Consume prompt, retorna chunks en vivo. 

Recuperación y Síntesis de Contexto

El sistema aprovecha la memoria de OpenAI para reconstruir interfaces y comprimir información.

Recuperación Profunda (GET-Conversacion)

El backend cruza los metadatos de persistencia local con el historial íntegro almacenado en el hilo de OpenAI.

Generación de Resúmenes (GET-ResumenConversacion)

Extrae el historial del hilo y emite un prompt secundario para sintetizar la interacción en un bloque comprimido.



Retroalimentación y Escalamiento Estricto

Mecanismos para mejorar el modelo y transferir casos al soporte humano.



**Mensajes Calificados
(POST-Mensaje)**

Almacena la utilidad en la tabla MENSAJESCALIFICADOS, mapeando explícitamente el booleano BUTIL al mensaje dentro del hilo de IA.




**Escalamiento a Tiquetes
(POST-Tiquete)**

Impone una validación rígida de cardinalidad: una conversación admite un máximo de un (1) tiquete, protegiendo al sistema externo de saturación.

Gobernanza: El Mecanismo de Borrado Lógico

DELETE—Conversacion prioriza la integridad de las métricas sobre la destrucción de datos.



Ocultamiento Estructural

El registro no se elimina físicamente. El backend muta la etiqueta a NO VISIBLE.

Implicaciones

1. Frontend: Se filtran activamente los registros no visibles para una experiencia limpia.
2. Persistencia: Se retiene la metadata de consumo de tokens (QTOKENS) y auditoría.

Síntesis: El Ecosistema PatylA

Un middleware orquestador que mantiene el equilibrio entre tres pilares empresariales.

